




# Introdução à Assimilação de Dados (MET 563-3)

## Motivação - Métodos Baseados em Conjuntos

Dr. Carlos Frederico Bastarz  
Dr. Dirceu Luis Herdies

Programa de Pós-Graduação em Meteorologia  
(PGMET) do INPE

05 de Outubro de 2025





# Métodos Baseados em Conjuntos

## Sumário

1. Filtro de Kalman linear
2. Método de Monte Carlo
3. Ensembles
4. Ensemble Kalman Filter
  - 4.1 Histórico e desenvolvimento
  - 4.2 Características principais
  - 4.3 *Inflation*
  - 4.4 Localização
5. Visão geral sobre os esquemas derivados
6. Atividades realizadas no CPTEC com o método LETKF
7. Atividade - Filtro de Bayes Recursivo



# Métodos Baseados em Conjuntos

## 1. Filtro de Kalman linear

- O Filtro de Kalman calcula analiticamente a atualização do estado e da covariância, assumindo
  - Linearidade
  - Ruído gaussiano
- Processo é realizado em duas etapas
  - Previsão
  - Correção
- Na etapa de previsão
  - Ocorre a extrapolação do estado do modelo e da incerteza
- Na etapa da correção
  - Ocorre o cálculo da matriz ganho de Kalman (matriz peso, tal como na Interpolação Ótima)
  - Ocorre a atualização da estimativa do estado com as observações
  - Ocorre a atualização da estimativa da incerteza





# Métodos Baseados em Conjuntos

## 1. Filtro de Kalman linear

- Etapa de previsão

- 🖱 Extrapolação do estado do modelo e da incerteza

$$\mathbf{x}_k^b = \mathbf{M}_{k-1}(\mathbf{x}_{k-1}^a) + \mathbf{w}_{k-1}$$

$$\mathbf{P}_k^b = \mathbf{M}_{k-1}\mathbf{P}_{k-1}^a\mathbf{M}_{k-1}^T + \mathbf{Q}_{k-1}$$

- Onde:

- $\mathbf{x}_k^b$  é o vetor background no tempo  $k$
- $\mathbf{M}_{k-1}$  é o modelo de previsão (linear), integrado do tempo  $k-1$  até  $k$
- $\mathbf{x}_{k-1}^a$  é o vetor análise no tempo  $k-1$
- $\mathbf{w}_{k-1}$  é o erro do modelo, com covariância  $\mathbf{Q}_{k-1}$
- $\mathbf{P}_k^b$  é a covariância do background no tempo  $k$

- Etapa da correção

- 🖱 Cálculo da matriz ganho de Kalman (matriz peso, tal como na Interpolação Ótima)

$$\mathbf{K}_k = \mathbf{P}_k^b\mathbf{H}_k^T(\mathbf{H}_k\mathbf{P}_k^b\mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

- 🖱 Atualização da estimativa do estado com as observações

$$\mathbf{x}_k^a = \mathbf{x}_k^b + \mathbf{K}_k[\mathbf{y}_k - \mathbf{H}_k(\mathbf{x}_k^b)]$$

- 🖱 Atualização da estimativa da incerteza

$$\mathbf{P}_k^a = (\mathbf{I} - \mathbf{K}_k\mathbf{H}_k)\mathbf{P}_k^b$$

- Onde:

- $\mathbf{x}_k^b$  é o vetor análise no tempo  $k$
- $\mathbf{P}_k^a$  é a covariância da análise no tempo  $k$



# Métodos Baseados em Conjuntos

## 1. Filtro de Kalman linear

-  Vantagens do Filtro de Kalman linear
  - Além de estimar o estado do sistema (análise), estima analiticamente a covariância (incerteza)
    - Permite quantificar a confiança na análise
$$\mathbf{x}_k^a = \mathbf{x}_k^b + \mathbf{K}_k[\mathbf{y}_k - \mathbf{H}_k(\mathbf{x}_k^b)], \quad \mathbf{P}_k^a = (\mathbf{I} - \mathbf{K}_k\mathbf{H}_k)\mathbf{P}_k^b$$
    - A matriz  $\mathbf{K}$  (ganho de Kalman) ajusta a contribuição do modelo e da observação
-  Limitações do Filtro de Kalman linear
  - Não é adequado para sistemas de alta dimensão (e.g., atmosfera, oceado), pois as matrizes de covariâncias ( $\mathbf{P}^b$  e  $\mathbf{P}^a$ ) são explícitas e enormes
  - Requer que o modelo dinâmico seja linear



# Métodos Baseados em Conjuntos

## 2. Método Monte Carlo


- O método Monte Carlo foi introduzido nos anos 1940
  - John von Neumann, durante o desenvolvimento do projeto Manhattan (bomba atômica)
- **Premissa**
  - 💡 Se não é possível calcular algo diretamente, pode-se estimar o resultado por meio de simulações aleatórias
  - Qualquer método estatístico baseado em amostragem massiva para obter resultados numéricos



# Métodos Baseados em Conjuntos

## 2. Método Monte Carlo

-  Exemplo simples
  - Estimar o valor de  $\pi$  contando quantos pontos caem dentro de um quadrado que contém um círculo inscrito (a razão entre os pontos dentro do círculo e o total é  $\approx \frac{\pi}{4}$ )



# Métodos Baseados em Conjuntos

## 2. Método Monte Carlo

- 🍰 Estimativa do valor de  $\pi$

```
import numpy as np

np.random.seed(42)

N = 1000000
x = np.random.rand(N)
y = np.random.rand(N)
dentro_circulo = (x**2 + y**2) <= 1

estima_pi = 4 * np.sum(dentro_circulo) / N
print(estima_pi)
```

- 📌 Resultados

| Valores de N | Valores de $\pi$ |
|--------------|------------------|
| 1            | 0,0              |
| 10           | 2,8              |
| 100          | 3,2              |
| 1.000        | 3,112            |
| 10.000       | 3,1556           |
| 100.000      | 3,1376           |
| 1.000.000    | 3,141864         |
| 10.000.000   | 3,1415772        |



# Métodos Baseados em Conjuntos

## 3. Ensembles




- Ensemble ou conjunto (de análises ou previsões) representam múltiplas simulações para a mesma data alvo
  - O objetivo é tentar amostrar a incerteza do modelo
- Diferentes técnicas podem ser utilizadas para se construir um ensemble
  - 🖱 O mais simples: utilizar previsões de diferentes modelos (superensemble)
    - A desvantagem: pós-processar diferentes previsões de diferentes modelos
  - 🖱 O mais complexo: utilizar assimilação de dados
    - A vantagem: fornece um ensemble de análises e previsões
  - Outras técnicas:
    - *Poor man's ensemble*: utiliza análises defasadas para gerar um ensemble inicial de previsões
    - Perturbação de física: utiliza diferentes parametrizações físicas do modelo para construir o ensemble
    - EOF: Funções Ortogonais Empíricas, utilizado pelo CPTEC
    - *Singular Vectors*: utilizado pelo ECMWF
    - *Bred Vectors*: utilizado pelo NCEP (passado)
    - EnKF: Ensemble Kalman Filter para assimilação de dados (e técnicas derivadas)

# Métodos Baseados em Conjuntos

## 3. Ensembles

- **Benefícios**

- Em geral, a média de um ensemble (bem construído) fornece uma boa estimativa em relação à previsão determinística (o skill tende a ser melhor)
- Fornece também a incerteza da previsão (*spread* ou espalhamento do ensemble)




# Métodos Baseados em Conjuntos

## 3. Ensembles

- **Desafios**

- Custo computacional (relação tamanho do ensemble X resolução espacial)
- Armazenamento
- Subestimativa da incerteza (*undersampling*) devido ao tamanho do ensemble
- Acurácia e precisão




- 🧠 Qual destas situações é acurada e precisa?



# Métodos Baseados em Conjuntos

## 3. Ensembles

- As previsões de um modelo numérico podem conter viés e erros sistemáticos
  - O viés é uma medida do erro aleatório do modelo e está relacionado com a precisão na representação dos estados do modelo
    - 🖱️ Pode-se corrigir as previsões no pós-processamento
  - O erro sistemático está relacionado com a acurácia com a qual um modelo numérico representa estes estados
    - 🖱️ Deve-se corrigir o modelo antes que as previsões sejam feitas



# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.1 Histórico e desenvolvimento

- 📖 O Kalman Filter linear foi introduzido em 1960:
  - *A New Approach to Linear Filtering and Prediction Problems* (Kalman, 1960)
  - <https://x.gd/VllfX>
- 📖 O Ensemble Kalman Filter foi introduzido em 1994:
  - *Sequential data assimilation with a nonlinear quasi-geostrophic model using Monte Carlo methods to forecast error statistics* (Evensen, 1994)
  - <https://x.gd/VsQ1V>
- 🖨 Com a evolução dos computadores e o aumento da complexidade do sistema de observação global, novas técnicas derivadas do EnKF surgiram:
  - EnSRF - *Ensemble Square Root Filter*
  - ETKF - *Ensemble Transform Kalman Filter*
  - LETKF - *Local Ensemble Transform Kalman Filter*

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.2 Características principais

- 🖱️ O Filtro de Kalman por conjunto é um filtro do tipo Monte Carlo
  - Assume que os erros são gaussianos
  - Assume que as relações entre os estados são lineares
  - Usa as matrizes de covariâncias para quantificar as incertezas
- ❤️ **O problema**
  - Em sistemas reais (e.g., atmosfera, oceano), é impossível armazenar e propagar a matriz de covariâncias completa
- 💡 **A solução**
  - Ao invés de armazenar as matrizes de covariâncias (teóricas) gigantes, o EnKF estima estas matrizes a partir de um conjunto de amostras (ensemble)



# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.2 Características principais

- O EnKF foi desenvolvido mantendo as principais características do filtro de Kalman linear, mas com as diferenças
  - 📌 Estimativa das covariâncias feita com base nos membros do ensemble e não via matriz explícitas
  - 📌 Matriz ganho de Kalman é conceitualmente igual, mas também calculada a partir do ensemble

$$\mathbf{K}_k = \mathbf{P}_k^b \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k^b \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

- 💡 A propagação das covariâncias é feita pela propagação do ensemble
- 💡 Permite tratar a não linearidade, pois cada membro do ensemble pode evoluir pelo modelo não linear completo
- O EnKF original é estocástico, no sentido de que as observações são perturbadas para gerar um conjunto de análises

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.2 Características principais

- No EnKF, a covariância dos erros de previsão ( $\mathbf{P}_k^b = \mathbf{M}_{k-1} \mathbf{P}_{k-1}^a \mathbf{M}_{k-1}^T + \mathbf{Q}_{k-1}$ ) é substituída pela covariância do conjunto

$$\mathbf{P}_k^b = \frac{1}{N-1} \mathbf{X}_k^b (\mathbf{X}_k^b)^T$$

◦ Onde:

- $\mathbf{X}_k^b$  é a matriz de perturbação do ensemble (desvio em relação à média)

- $\mathbf{X}_k^{b(i)} = \mathbf{x}_k^{b(i)} - \bar{\mathbf{x}}_k^b$

- $\bar{\mathbf{x}}_k^b = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_k^{b(i)}$

◦ 🧠 Por que  $\mathbf{P}^b$  é calculada considerando  $N - 1$  membros (fator de correção de Bessel)?

- Usar  $N$  no denominador do fator de correção, torna a estimativa tendenciosa, pois subestima a (co)variância real
- Usar  $N - 1$  no denominador do fator de correção, evita a estimativa tendenciosa e  $\mathbf{P}^b$  coincide com a covariância verdadeira

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.2 Características principais

- Erro do modelo X Erro da previsão
- Na equação da covariância do erro da previsão

$$\mathbf{P}_k^b = \mathbf{M}_{k-1} \mathbf{P}_{k-1}^a \mathbf{M}_{k-1}^T + \mathbf{Q}_{k-1}$$

- Os termos  $\mathbf{P}^b$  e  $\mathbf{Q}$  são semelhantes, mas possuem significados diferentes
  - $\mathbf{P}^b$  representa a covariância total da incerteza do modelo (o quanto o EnKF confia nas previsões)
  - $\mathbf{Q}$  representa o erro introduzido pelo modelo (parametrizações, método numérico etc)

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.2 Características principais

- Se o conjunto for pequeno, as covariâncias são subestimadas
- Quanto maior o conjunto, melhor será a representação das covariâncias
  - 🧠 Qual é o tamanho ideal de um conjunto para que se tenha a melhor estimativa das covariâncias do ("erro") do modelo?
- Perturbação das observações
  - Cada observação  $\mathbf{y}_k$  é perturbada com um ruído aleatório, extraído da distribuição do erro de observação com covariância  $\mathbf{R}_k$

$$\mathbf{y}_k^{(i)} = \mathbf{y}_k + \epsilon_k^{(i)}, \quad \epsilon_k^{(i)} \sim \mathcal{N}(0, \mathbf{R}_k)$$

- Cada membro  $i$  do ensemble recebe uma versão ligeiramente diferente das observações reais
- O ruído  $\epsilon_k^{(i)}$  é independente entre os membros e com média zero e covariância  $\mathbf{R}_k$
- 👉 Isso é o que garante que o EnKF não colapse, pois garante a dispersão (da covariância) do ensemble



# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.3 *Inflation*

- 🏃 No ciclo de assimilação de dados do EnKF, as observações são utilizadas para corrigir o estado do modelo
  - 💡 Mas o EnKF perturba o modelo para amostrar a sua incerteza
  - 🤖 Ambiguidade
    - Ao mesmo tempo que se perturba do estado, tenta-se corrigi-lo
  - 👉 Então, ao longo do tempo, a tendência é a de que a incerteza do EnKF seja cada vez mais subestimada, de forma que seja necessário inflar o spread (espalhamento ou incerteza) do conjunto

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.3 Inflation

- No EnKF,  $\mathbf{P}^f$  é estimada a partir de um número finito de membros
  - Como consequência, a estimativa da incerteza do modelo é subestimada
  - Isso faz com que o filtro confie mais nas previsões e menos nas observações!
  - Problemas podem ocorrer com a divergência do filtro
    - 🕒 Com o tempo, o modelo se afasta das observações
  - 💡 O *inflation* é um mecanismo artificial para aumentar a variância do ensemble

$$\mathbf{x}_i^I = \bar{\mathbf{x}} + \sqrt{\lambda}(\mathbf{x}_i - \bar{\mathbf{x}})$$

- Cada membro é "inflado" em torno da média do ensemble 🖱️ é empírico!
- Onde:
  - $\mathbf{x}_i^I$  é o membro do ensemble com variância inflada
  - $\bar{\mathbf{x}}$  é a média do ensemble
  - $\lambda$  é o fator de inflação ( $\lambda \in \mathbb{R}$ )
- $\lambda = 1$ : não inflaciona o ensemble
- $\lambda > 1$ : aumenta a dispersão do ensemble 🖱️ aumenta a incerteza 🖱️ aumenta a variância
- $\lambda < 1$ : diminui a dispersão do ensemble 🖱️ diminui a incerteza 🖱️ diminui a variância
- Se o ensemble for pequeno, maior é o valor de  $\lambda$

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.3 *Inflation*

- A escolha de um valor para  $\lambda$  é empírica e depende do tamanho do ensemble
  - Quanto menor o ensemble, maior pode ser o valor de  $\lambda$
- O *inflation* pode ser implementado de forma que seja adaptativo
  - Pode variar em função do spread e do erro da análise

# Métodos Baseados em Conjuntos

## 4. Ensemble Kalman Filter

### 4.3 Localização

- A localização é utilizada para compensar o efeito cíclico de correções sobre o espalhamento do conjunto de previsões devido ao seu tamanho, para evitar
  - Covariâncias espúrias
    - Se o ensemble for pequeno, a amostragem das covariâncias é ruim, o que faz com que covariâncias distantes não reflitam as relações físicas reais
  - Custo computacional alto
    - A localização limita a covariância entre variáveis de estado que estão muito longe umas das outras

$$\mathbf{P}_f^L = \mathbf{P}_f \circ \mathbf{L}$$

- Onde:
  - $\mathbf{L}$  é uma função de correlação (funciona como um raio de influência)

# Métodos Baseados em Conjuntos

## 5. Visão geral sobre os esquemas derivados

- EKF - *Extended Kalman Filter*
  - É uma extensão do Filtro de Kalman linear para sistemas não lineares
  - Lineariza o modelo e o operador observação ao redor do estado estimado
- EnSRF - *Ensemble Square Root Filter*
  - É a forma determinística do EnKF (o EnKF é estocástico porque perturba as observações!)
  - Cada membro é atualizado em torno da média do ensemble
- LETKF - *Local Ensemble Kalman Filter*
  - Atualiza cada ponto de grade de forma independente no espaço do ensemble (é mais eficiente)



# Métodos Baseados em Conjuntos

## 5. Visão geral sobre os esquemas derivados

### EKF - *Extended Kalman Filter*

- É uma extensão do Filtro de Kalman linear para sistemas não lineares (não é ensemble!)
- Lineariza o modelo e o operador observação ao redor do estado estimado

- Equações do modelo

$$\mathbf{x}_k^b = M_{k-1}(\mathbf{x}_{k-1}^a) + \mathbf{w}_{k-1}$$
$$\mathbf{P}_k^b = \mathbf{M}_{k-1} \mathbf{P}_{k-1}^a \mathbf{M}_{k-1}^T + \mathbf{Q}_{k-1}$$

- Equações da análise

$$\mathbf{K}_k = \mathbf{P}_k^b \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k^b \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$
$$\mathbf{x}_k^a = \mathbf{x}_k^b + \mathbf{K}_k [\mathbf{y}_k - H(\mathbf{x}_k^b)]$$
$$\mathbf{P}_k^a = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_k^b$$

- Onde:

- $\mathbf{M}_{k-1} = \frac{\partial M}{\partial \mathbf{x}} \Big|_{\mathbf{x}_{k-1}^a}$  é a matriz jacobiana do operador observação
- $\mathbf{H}_k = \frac{\partial H}{\partial \mathbf{x}} \Big|_{\mathbf{x}_k^b}$  é a matriz jacobiana do operador observação

# Métodos Baseados em Conjuntos

## 5. Visão geral sobre os esquemas derivados

### EnSRF - *Ensemble Square Root Filter*

- É a forma determinística do EnKF (o EnKF é estocástico porque perturba as observações!)
- Cada membro é atualizado em torno da média do ensemble

- Atualização do ensemble médio (análise)

$$\begin{aligned}\bar{\mathbf{x}}_k^a &= \bar{\mathbf{x}}_k^b + \mathbf{K}_k(\mathbf{y}_k - \bar{\mathbf{y}}_k^b) \\ \mathbf{K}_k &= \mathbf{P}_{xy,k}^b (\mathbf{P}_{yy,k}^b + \mathbf{R}_k)^{-1} \\ \mathbf{P}_{xy,k}^b &= \frac{1}{N-1} \mathbf{X}_k^b (\mathbf{Y}_k^b)^T, \quad \mathbf{P}_{yy,k}^b = \frac{1}{N-1} \mathbf{Y}_k^b (\mathbf{Y}_k^b)^T\end{aligned}$$

- Atualização das anomalias (covariâncias)

$$\begin{aligned}\mathbf{x}_k^{a(i)} &= \bar{\mathbf{x}}_k^a + \mathbf{X}_k^{a(i)} \\ \mathbf{X}_k^a &= \mathbf{X}_k^b \mathbf{T}_k \\ \mathbf{T}_k \mathbf{T}_k^T &= \mathbf{I} - \frac{\mathbf{Y}_k^{bT} (\mathbf{P}_{yy,k}^b + \mathbf{R}_k)^{-1} \mathbf{Y}_k^b}{N-1}\end{aligned}$$

- Onde:

- $\mathbf{P}_{xy,k}^b$  e  $\mathbf{P}_{yy,k}^b$  são covariâncias cruzadas entre o espaço do modelo e o espaço físico (observações)
- $\mathbf{T}_k$  é a matriz square root (raiz quadrada) que garante que as covariâncias do ensemble correspondam às covariâncias do filtro de Kalman linear, sem precisar perturbar as observações

# Métodos Baseados em Conjuntos

## 5. Visão geral sobre os esquemas derivados

### LETKF - *Local Ensemble Kalman Filter*

- Atualiza cada ponto de grade de forma independente no espaço do ensemble (é mais eficiente)

- Matriz peso da análise ( $\mathbf{W}$ ) no espaço do ensemble:

$$\mathbf{Y}_k^b = [\mathbf{y}_k^{b(1)} - \bar{\mathbf{y}}_k^b \cdots \mathbf{y}_k^{b(N)} - \bar{\mathbf{y}}_k^b]$$
$$\mathbf{W}_k^a = [ (N-1)\mathbf{I} + (\mathbf{Y}_k^b)^T \mathbf{R}^{-1} \mathbf{Y}_k^b ]^{-\frac{1}{2}}$$

- Matriz de ganho transformado

$$\mathbf{K}_w = \mathbf{W}_k^a (\mathbf{Y}_k^b)^T \mathbf{R}^{-1}$$

- Atualização da média e anomalias no espaço dos pesos

$$\bar{\mathbf{w}}_k^a = \mathbf{K}_w (\mathbf{y}_k - \bar{\mathbf{y}}_k^b)$$
$$\mathbf{W}_k^{a(i)} = \bar{\mathbf{w}}_k^{a(i)} + \mathbf{W}_k^a \mathbf{e}^{(i)}$$

- Equação da análise no espaço do modelo

$$\mathbf{x}_k^{a(i)} = \bar{\mathbf{x}}_k^b + \mathbf{X}_k^b \mathbf{W}_k^{a(i)}$$

- Onde:

- $\mathbf{e}^{(i)}$  são os vetores unitários que definem cada membro no espaço reduzido do ensemble

# Métodos Baseados em Conjuntos

## 6. Atividades realizadas no CPTEC com o método LETKF

- Por volta de 2009, o grupo de assimilação de dados do CPTEC vinha estudando a aplicação do LETKF como método substituto para a sua análise operacional em domínio global
  - Resolução: TQ0126L028 (aproximadamente 100 km de resolução espacial horizontal e 28 níveis verticais em coordenada sigma)
  - 40 membros
-  **Desafios**
  - Desempenho computacional para um conjunto grande de membros (aumento da resolução ficou limitado ao tamanho do conjunto)
  - Assimilação de radiâncias (necessidade de desenvolvimento de diferentes operadores  $H$  para diferentes tipos de observações não convencionais)

# Métodos Baseados em Conjuntos

## 6. Atividades realizadas no CPTEC com o método LETKF

- LETKF permaneceu como método de pesquisa do CPTEC
  - **2010** - Tese Rosângela Cintra: "Assimilação de Dados com Redes Neurais Artificiais em Modelo de Circulação Geral da Atmosfera"
  - **2010** - Pós-Doutorado José Aravéquia: "Evaluation of a Strategy for the Assimilation of Satellite Radiance Observations with the Local Ensemble Transform Kalman Filter"
  - **2011** - Dissertação Maria Medeiros: "Impacto do Uso de Radiância na Assimilação de Dados usando 4D-LETKF na Região da América do Sul"
  - **2013** - Bolsa PCI Lucas Avanço: "Assimilação de Dados de Rádio Ocultação GNSS no LETKF: Disponibilidade de Dados e Implementação de um Operador"
  - **2018** - Tese Helena Barbieri: "Ajuste Dinâmico para Análise Híbrida entre um Sistema Variacional e Filtro de Kalman por Conjunto"
  - **2018** - Tese Leonardo Lima: "Estudo das Incertezas na Simulação por Conjuntos e no Uso da Assimilação de Dados no Oceano Atlântico Sudoeste"
  - Entre outros...

# Ninja Vs. Codorna





# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

Ninja Vs. Codorna



- Uma codorna 🦜 pia no meio da mata
- Um ninja 🥷 escuta...
- A codorna pia mais uma vez
- O ninja escuta novamente...
- O ninja quer saber **onde está a codorna**
- A codorna pia novamente...
- E ela faz isso mais 100 vezes
- **Pergunta**
  - 🧠 Será o ninja capaz de descobrir a posição da codorna no meio da mata? (continua...)

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

- **Palavras-chave**

- **Hipótese:** uma pergunta - uma teoria seria uma afirmação?
- **Dado:** uma informação, uma observação
- **Verossimilhança:** (ou *likelihood*) o grau de veracidade de uma determinada informação
- **Informação à *priori*:** (ou *prior*) aquilo que se conhece a princípio
- **Informação à *posteriori*:** (ou *posterior*) aquilo que se conclui a partir da informação à *priori*
- **Probabilidade conjunta:** probabilidade de dois ou mais eventos ocorrerem simultaneamente

- **Conceito-chave**

- **Probabilidade condicional:** ocorrência de um evento dada uma informação à *priori*

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

- Teorema de Bayes

$$p(h|d) = \frac{p(d|h)p(h)}{p(d)}$$

- Onde:

- $h$ : é a hipótese
- $d$ : é o dado observado (uma informação observada)
- $p(h|d)$ : é o *posterior* (ou *posteriori*, é a probabilidade da hipótese após observar o dado)
- $p(h)$ : é o *prior* (é a probabilidade atribuída à hipótese antes de ver o dado)
- $p(d)$ : é a probabilidade do dado (constante de normalização)
- $p(d|h)$ : verossimilhança (é a probabilidade de observar o dado, considerando-se a hipótese verdadeira)

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Probabilidade Vs. Verossimilhança

- Probabilidade
  - É a chance de ocorrência de um determinado evento possível
- Verossimilhança
  - É provável (ou possível) que este evento exista? Este evento é plausível?
- Para que um determinado evento ocorra, é necessário que ele exista e que pertença a um determinado conjunto de eventos possíveis
  - A máxima verossimilhança destaca, portanto, o quão verossímil é a probabilidade do evento

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Verossimilhança

- Considere que você observa o lançamento de 20 dados  sobre uma mesa e deseja saber qual é a verossimilhança desta observação - todos os dados apresentam os mesmos valores
- Para isto, consideramos duas hipóteses:
  1. Dado viciado
  2. Dado não viciado

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Dado viciado

- Neste caso, os 20 dados apresentam o mesmo valor (e.g., 5)
  - A probabilidade conjunta destes eventos

$$p(dado_1) \times p(dado_2) \times \dots \times p(dado_{20}) = \left(\frac{1}{1}\right)^{20} = 1$$

### Dado não viciado

- Neste caso, cada um dos 20 dados possui a mesma probabilidade de apresentar um dos 6 números possíveis
  - A probabilidade conjunta neste caso é  $\left(\frac{1}{6}\right)^{20} \approx 0$
- 🖐️ Portanto, é muito mais verossímil que o dado seja viciado dada a observação inicial

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Provabilidade Vs. Verossimilhança

- Exemplo
  - $d$ : o ninja 🥷 ouve um canto na mata
  - $h$ : há uma codorna 🐦 na mata
  - $L(h|d)$ : é a verossimilhança
    - $p(d|h) \neq p(h|d)$ : o fato de o ninja ouvir um canto na mata, dado que há uma codorna na mata, não significa que dado que há uma codorna na mata, o ninja ouvirá um canto - ela pode estar dormindo 🐦 zzz
    - $p(h|d)$ , então  $l(h|d)$  é baixa: se há uma codorna na mata, não necessariamente ela está cantando e o que o ninja ouve não é uma codorna, mas sim um pardal 🐦
    - $p(d|h)$ , então  $l(h|d)$  é alta: se há uma codorna na mata, então há um canto ecoando na mata



# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Estimativa de Máxima Verossimilhança

- Permite estimar, por exemplo, os momentos estatísticos de uma determinada distribuição. Por exemplo:
  - Quais são os valores de média ( $\mu$ ) e desvio-padrão ( $\sigma$ ) que maximizam a probabilidade de um determinado evento (ou hipótese) ou dado observado?
  - Em outras palavras, quais são os valores de  $\mu$  e  $\sigma$  que tornam os dados observados mais prováveis (considerando que os dados vem de uma distribuição normal  $\mathcal{N}(\mu, \sigma^2)$ )?

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Exemplo de Inferência Bayesiana (ou Filtro Bayesiano)

- Kalnay (2002) <sup>♦</sup> : dadas duas observações independentes  $T_1$  e  $T_2$ , as quais são assumidas possuírem distribuição normal e erros com desvios-padrão  $\sigma_1$  e  $\sigma_2$ , qual é o valor mais provável de  $T$ ? Neste caso, define-se a análise como sendo o valor mais provável de  $T$  dadas as observações e as suas estatísticas de erro:

$$p(T|T_1, T_2) = \frac{p(T)p(T_1, T_2|T)}{p(T_1, T_2)}$$

---

<sup>♦</sup> Kalnay, E. (2002). Atmospheric Modeling, Data Assimilation and Predictability. Cambridge: Cambridge University Press.

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo


- Distribuição Normal - ou Gaussiana

$$p_{\sigma_1}(T_1|T) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(T_1-T)^2}{2\sigma_1^2}}$$

$$p_{\sigma_2}(T_2|T) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(T_2-T)^2}{2\sigma_2^2}}$$

- O valor mais provável (*likely*) de  $T$  dadas as observações independentes  $T_1$  e  $T_2$ , é aquele que maximiza a **probabilidade conjunta**, ou seja, o produto de  $p_{\sigma_1}$  e  $p_{\sigma_2}$ :

$$p_{\sigma_1}(T_1|T)p_{\sigma_2}(T_2|T) = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{(T_1-T)^2}{2\sigma_1^2} - \frac{(T_2-T)^2}{2\sigma_2^2}}$$



# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo


Prior, posterior, likelihood, distribuição de probabilidade...

- Teorema de Bayes

$$p(h|d) = \frac{p(d|h)p(h)}{p(d)}$$

- Distribuição Gaussiana

$$p_{\sigma_1}(T_1|T) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(T_1-T)^2}{2\sigma_1^2}}$$



# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

### Inferência Bayesiana Recursiva (ou "Filtro de Bayes Recursivo")


- Um ninja ouve o canto intermitente de uma codorna (ela está parada)
- A cada canto, ele tenta descobrir a posição da codorna
  - 🧠 Como o ninja pode inferir a posição da codorna?
- Um outro problema real poderia ser: ajustar um modelo aos valores observados a cada ciclo de análise
  - 🧠 Como isso pode ser feito de forma iterativa?

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo


### Exemplo prático: Ninja Vs. Codorna

- Método Monte Carlo
  - ● posição real da codorna
  - + posição da codorna, segundo o ninja ( $N = 100$ )
- A cada canto da codorna, o ninja tenta descobrir a posição real da ave
- O ninja pode modelar a situação e, com um número finito de tentativas, pode estimar a posição mais provável da codorna



# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo



- Para cada posição inferida pelo ninja, a "função iterativa de Bayes", calcula a verossimilhança da posição:

```
m[i,j] = norm * np.exp(np.matmul(-(x[:,n] - me), np.matmul(inv, (x[:,n] - me) / 2.)))
```

- Ou seja,

$$p_{\sigma_1}(T_1|T) = \frac{1}{\sqrt{2\pi\sigma_1}} e^{-\frac{(T_1-T)^2}{2\sigma_1^2}}$$

- A melhor estimativa obtida pelo ninja utilizando-se a inferência Bayesiana recursiva, é chamada de "Estimativa de Máxima Verossimilhança" e representa o valor mais provável a ser obtido (cores mais quentes na superfície) da posição da codorna

# Métodos Baseados em Conjuntos

## 7. Atividade - Filtro de Bayes Recursivo

 Notebook com [Atividade Prática 7](#)



# 🤔 Dúvidas

🔗 <https://cfbstarz.github.io/met563-3/>

👤 <https://github.com/cfbstarz/MET563-3>

✉️ [carlos.bastarz@inpe.br](mailto:carlos.bastarz@inpe.br)

