




Introdução à Assimilação de Dados (MET 563-3)

Método Variacional - Parte (I)II

Dr. Carlos Frederico Bastarz
Dr. Dirceu Luis Herdies

Programa de Pós-Graduação em Meteorologia
(PGMET) do INPE

30 de Outubro de 2025

Método Variacional

Sumário

Parte I

1. Cálculo variacional
2. Revisão de Álgebra Linear (Matrizes)
3. Introdução ao método 3DVar
 - 3.1 Filtragem Vs. Suavização
 - 3.2 Histórico e desenvolvimento
 - 3.3 Formulação Matemática do 3DVar
 - 3.4 Características principais
 - 3.5 O Ciclo de Assimilação de Dados
 - 3.6 *Physical-space Statistical Analysis System* (PSAS)
 - 3.7 *First Guess at Appropriate Time* (FGAT)

Parte II

4. Componentes
 - 4.1 Método de minimização do Gradiente Descendente
 - 4.2 Matriz de covariâncias dos Erros de Previsão
 - ~~4.3 Modelo de Transferência Radiativa~~
 - ~~4.4 Controle de Qualidade~~
5. Visão geral sobre o método 4DVar
6. Atividades realizadas no CPTEC com o método variacional

Método Variacional - Parte I

3. Introdução ao Método 3DVar

- O 3DVar é uma das primeiras aplicações do cálculo variacional em meteorologia
 - **Objetivo:** combinar previsão do modelo e observações para obter a melhor estimativa do estado atmosférico

- **Função Custo:**

$$J(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}_b)^T \mathbf{B}^{-1}(\mathbf{x} - \mathbf{x}_b) + \frac{1}{2}[\mathbf{y}_o - H(\mathbf{x})]^T \mathbf{R}^{-1}[\mathbf{y}_o - H(\mathbf{x})]$$

- **Gradiente:**

$$\nabla J(\mathbf{x}) = (\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})(\mathbf{x} - \mathbf{x}_b) - (\mathbf{H}^T \mathbf{R}^{-1})[\mathbf{y}_o - H(\mathbf{x}_b)] = 0$$

- **Solução Analítica Exata:** ♦

$$\mathbf{x}_a = \mathbf{x}_b + \mathbf{W}[\mathbf{y}_o - H(\mathbf{x}_b)], \quad \mathbf{W} = \mathbf{B}\mathbf{H}^T(\mathbf{H}\mathbf{B}\mathbf{H}^T + \mathbf{R})^{-1}$$

👉 O 3DVar foi implementado operacionalmente no ECMWF em 1996 e foi substituído pelo 4DVar em 1997; 👉 No CPTEC, o 3DVar começou a ser aplicado em 1997

♦ Utilizando a identidade de Sherman-Morrison-Woodbury

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.1 Filtragem Vs. Suavização

- **Filtragem:**
 - Quando o estado do sistema é atualizado a cada passo de tempo, incorporando novas informações (e.g., IO, 3DVar, EnKF)
- **Suavização:**
 - Quando a atualização do estado do sistema depende de toda a informação, durante todo o período de atualização (e.g., 4DVar)
- **4DDA:**
 - *Four Dimentional Data Assimilation* - leva em conta a variação temporal e espacial dos dados observados durante um intervalo de tempo (e.g., FGAT, 4DVar)

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.2 Histórico e Desenvolvimento

- Décadas de 1970–1980: Ideia variacional começa a ser aplicada à meteorologia
- Década de 1990: implementação do 3DVar no ECMWF e do PSAS ♦ na NASA
- Motivação: superar as limitações da Interpolação Ótima
 - IO: Atualiza o background ponto a ponto, combinações locais entre previsão e observação
 - 3DVar: Minimiza a função custo de forma global e possui estrutura matricial
 - 4DVar: Estende o 3DVar no tempo e considera a dinâmica do modelo


♦ PSAS: *Physical-space Statistical Analysis System*

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.2 Histórico e Desenvolvimento

- Evolução do skill da previsão da altura geopotencial em 500 hPa:
 - No início dos anos 1980, a previsão de 7 dias para o Hemisfério Norte, o skill da previsão não chegava a 50%, sendo inferior a 40% no Hemisfério Sul
 - Com o tempo, a diferença do skill entre os hemisférios diminuiu drasticamente, sendo muito próximos a partir dos anos 2000
 - Apenas a partir da metade dos anos 1990, a previsão de 10 dias começa a atingir algum skill (~30%)...
 - Atualmente, a previsão de 10 dias já alcança skill de 50% para ambos os hemisférios
 - Embora a melhoria tenha sido importante, parece que o skill das previsões mais curtas está alcançando o seu limite - **por que?**



Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.3 Formulação Matemática do 3DVar ♦

- Hipóteses:

- O erro do background $\epsilon_b = x_b - x_t$ (x_t é o estado verdadeiro, gaussiano - média zero e covariância $\mathbf{B}$)

$$p(x_t|x_b) \propto \exp\left[-\frac{1}{2}(x_t - x_b)^T \mathbf{B}^{-1}(x_t - x_b)\right]$$

- O erro da observação $\epsilon_o = y_o - H(x_t)$ (gaussiano - média zero e covariância $\mathbf{R}$)

$$p(y_o|x_b) \propto \exp\left\{-\frac{1}{2}[y_o - H(x_t)]^T \mathbf{R}^{-1}[y_o - H(x_t)]\right\}$$

- Pelo Teorema de Bayes, temos:

$$p(x|y_o) \propto p(y_o|x)p(x)$$

- Onde:

- $p(y_o|x)$ é a verossimilhança
- $p(x)$ é a probabilidade à priori (background)
- $p(x|y_o)$ é a probabilidade à posteriori (o que queremos maximizar)

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.3 Formulação Matemática do 3DVar

- A função de verossimilhança expressa o quanto as observações y_o são prováveis dado um estado do x :

$$L(x) = p(y_o|x)$$

- Substituindo as expressões gaussianas dos erros do background $p(x_t|x_b)$ e das observações $p(y_o|x_t)$, obtemos:

$$p(x|y_o) \propto \exp\left[-\frac{1}{2}(x - x_b)^T \mathbf{B}^{-1}(x - x_b)\right] \exp\left\{-\frac{1}{2}[y_o - H(x)]^T \mathbf{R}^{-1}[y - H(x)]\right\}$$

- Maximizar $p(x|y_o)$ significa obter o estado mais provável e é o mesmo que minimizar o negativo do logartímo dessa probabilidade (o que garante que estaremos minimizando o funcional):

$$J(x) = -\ln p(x|y_o)$$

$$J(x) = -\frac{1}{2}(x - x_b)^T \mathbf{B}^{-1}(x - x_b) - \frac{1}{2}[y_o - H(x)]^T \mathbf{R}^{-1}[y - H(x)]$$

- Portanto, quando consideramos erros gaussianos e estimativa de máxima verossimilhança, essencialmente, estamos fazendo o mesmo que a estimativa de variância mínima 🤖

Método Variacional - Parte I

3. Introdução ao Método 3DVar


3.4 Características principais

- **Três dimensões espaciais** (sem dependência temporal)
- **Estacionário:** $\mathbf{B}$ fixa no tempo (matriz "estática" ou "climatológica")
- **Análise síncrona:** usa observações de um único instante (e.g., centradas na janela de 6 horas)
- **Métodos de minimização:** gradiente descendente, gradiente conjugado
- **Robusto** e adequado para assimilar milhões de observações em alta resolução espacial
 - Mas temporalmente inconsistente

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.5 O ciclo de assimilação de dados




Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.5 O ciclo de assimilação de dados

- 🏃 O ciclo se inicia com uma previsão de curto prazo (*first guess* ou *background*), tipicamente de 6 horas
- 🖱️ As observações são utilizadas para atualizar/corrigir a previsão de curto prazo
 - 🌍 No método variacional, essa atualização/correção é feita a partir da minimização da função custo
- ✅ Ao final deste processo, obtém-se um estado atualizado denominado de análise, o qual é válido para o mesmo horário de referência das observações




Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.5 O ciclo de assimilação de dados

- Exemplo:
 - Sistema de Modelagem Numérica e Assimilação de dados (SMNA)
 - SMNA = BAM + GSI
 - 3DVar + FGAT
 - TQ2099L064 (~ 45km de res. horizontal e 64 níveis, coord. vert. híbrida)
 - Operacional XC50



Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.6 *Physical-Space Statistical Analysis System (PSAS)*

- Introduzido pelo DAO [♦] (atualmente GMAO [♦] da NASA) em meados dos anos 1990
 - Arlindo da Silva e Ricardo Todling (dois brasileiros) participaram do seu desenvolvimento
 - Foi desenvolvido para substituir o esquema de IO utilizado com o modelo GEOS da NASA
 - É um algoritmo variacional com características de IO

- Premissas (à época):
 - Utilizar o mesmo modelo de covariâncias dos erros de observação e previsão da IO, mas resolver a equação de análise globalmente
 - Permitir maior flexibilidade na modelagem da covariância dos erros de observação e previsão - a formulação da equação de análise no espaço físico das observações permite a representação das covariâncias anisotrópicas e dependentes do fluxo atmosférico
 - Permitir a assimilação de novos tipo de dados não convencionais
 - Permitir novos avanços nas metodologias de assimilação de dados

[♦] DAO: *Data Assimilation Office*

[♦] GMAO: *Global Modeling and Assimilation Office*

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.6 *Physical-Space Statistical Analysis System (PSAS)*

- Equação de análise (semelhante à da IO):

$$\delta \mathbf{x}_a = (\mathbf{B}\mathbf{H}^T)(\mathbf{R} + \mathbf{H}\mathbf{B}\mathbf{H}^T)^{-1}\delta \mathbf{y}_o$$

- A solução é separada em duas etapas:

1. Resolver a parte do peso e da inovação:

$$\mathbf{w} = (\mathbf{R} + \mathbf{H}\mathbf{B}\mathbf{H}^T)^{-1}\delta \mathbf{y}_o$$

2. Resolver o incremento de análise:

$$\delta \mathbf{x}_a = (\mathbf{B}\mathbf{H}^T)\mathbf{w}$$

Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.6 *Physical-Space Statistical Analysis System (PSAS)*

- Como o PSAS é um método variacional, $\delta \mathbf{x}_a$ é resolvida através da minimização da função custo:

$$J(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T (\mathbf{R} + \mathbf{H} \mathbf{B} \mathbf{H}^T) \mathbf{w} - \mathbf{w}^T [\mathbf{y}_o - H(\mathbf{x}_b)]$$

- Note que, em comparação com o 3DVar tradicional, o termo $\mathbf{w}^T (\mathbf{R} + \mathbf{H} \mathbf{B} \mathbf{H}^T) \mathbf{w}$ é equivalente a $(\mathbf{x} - \mathbf{x}_b)^T \mathbf{B}^{-1} (\mathbf{x} - \mathbf{x}_b)$
 - No PSAS, a análise é resolvida no espaço físico (espaço das observações)!
- Se o número de observações é muito menor do que número de graus de liberdade do modelo, o PSAS resolve a análise da mesma forma que o 3DVar, só que de forma mais rápida
 - 3DVar: resolve a análise no espaço do modelo (analisa muito mais pontos do que o PSAS)
 - PSAS: resolve a análise no espaço da observação (analisa menos pontos do que o 3DVar - se não houverem muitas observações)


Método Variacional - Parte I

3. Introdução ao Método 3DVar

3.7 *First Guess at Appropriate Time* (FGAT)

- FGAT é uma extensão do 3DVar para observações distribuídas no tempo
 - O background é interpolado no tempo da observação
 - Função custo continua 3D, pois não evolui a correção do background ao longo do tempo
- Melhora a sincronia temporal das observações:
 - Principalmente das observações que não estão no tempo da análise (observações não convencionais)
 - Exige que o first guess seja particionado na janela de assimilação

$$J(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}_b(t_0))^T \mathbf{B}^{-1}(\mathbf{x} - \mathbf{x}_b(t_0)) + \frac{1}{2} \sum_i [\mathbf{y}_i - H_i(\mathbf{x}(t_i))]^T \mathbf{R}_i^{-1} [\mathbf{y}_i - H_i(\mathbf{x}(t_i))]$$



Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

- Técnica iterativa para encontrar o mínimo de uma função
 - Se estivéssemos percorrendo um vale, o gradiente ♦ da função que descreve esse vale indicaria a direção de subida mais íngreme
 - Então, para descer o vale, deveríamos percorrer a direção oposta ao gradiente
- Se $J(\mathbf{x})$ é o funcional que queremos minimizar, ∇J é um vetor de derivadas parciais:

$$\nabla J(\mathbf{x}) = \begin{bmatrix} \frac{\partial J}{\partial x_1} \\ \frac{\partial J}{\partial x_2} \\ \vdots \\ \frac{\partial J}{\partial x_n} \end{bmatrix}$$

♦ O gradiente de uma função contínua, aponta para a direção onde a função cresce mais rápido

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

- O método iterativo atualiza a estimativa da solução com base no passo anterior, da seguinte forma:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \nabla J(\mathbf{x}_k)$$

ou

$$\mathbf{x}_k = \mathbf{x}_{k-1} - \alpha \nabla J(\mathbf{x}_{k-1})$$

- Onde:
 - $\mathbf{x}_k$ é a estimativa da solução no passo atual
 - α é a taxa de atualização (controla o tamanho da descida)
 - $\nabla J(\mathbf{x}_k)$ é o gradiente calculado no passo k

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples ♦

- Seja a função contínua real
 $y = f(x) = x^2 - 4x + 2$
- A derivada primeira de y é dada por: $y' = 2x - 4$
- Fazendo $y' = 0$, obtemos:
$$2x - 4 = 0$$
$$2x = 4$$
$$x = \frac{4}{2} = 2$$
- Substituindo $x = 2$ na função original, obtemos
 $y = -2$
- Logo, os valores de $x = 2$ e $y = -2$ encontrados, são as coordenadas do vértice da parábola definida pela função original.

♦ Baseado em <https://medium.com/@rrfd/what-is-a-cost-function-gradient-descent-examples-with-python-16273460d634>


Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples

- Os valores de $x = 2$ e $y = -2$ encontrados, são as coordenadas do vértice da parábola definida pela função original



Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples

- Definição da função $y = f(x)$ original:

```
# Definimos uma função que irá retornar  
# o valor de f(x) para uma lista de valores  
def func_y(x):  
    return x**2 - 4*x + 2
```

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples

- Função para calcular o gradiente descendente de $f(x)$:
 - `epoch` indexa o tempo
 - `learning_rate` é o valor de α

```
def gradient_descent_x(previous_x, learning_rate, epoch):  
  
    x_gd = []  
    y_gd = []  
  
    x_gd.append(previous_x)  
    y_gd.append(func_y(previous_x))  
  
    for i in range(epoch):  
        current_x = previous_x - learning_rate * (2*previous_x - 4)  
        x_gd.append(current_x)  
        y_gd.append(func_y(current_x))  
  
        previous_x = current_x  
  
    return x_gd, y_gd
```

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples

- Iniciamos a descida com um chute inicial para x ($x_0 = 4$)
- Faremos o mesmo com o valor de α , ajustando-o para $\alpha = 0,15$ (faremos com que a taxa de atualização seja de 15%)
- Faremos um total de 10 iterações

```
x0 = 4  
  
learning_rate = 0.15  
  
epoch = 10  
  
gd = gradient_descent_x(x0, learning_rate, epoch)
```

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples

- Valores de x ao longo das iterações:

```
xgd = gd[0]
xgd
[4,
 3.4,
 2.98,
 2.686,
 2.4802,
 2.33614,
 2.235298,
 2.1647086,
 2.11529602,
 2.0807072140000002,
 2.0564950498]
```

- Valores de y ao longo das iterações:


```
ygd = gd[1]
ygd
[2,
 -0.0400000000000000924,
 -1.0396,
 -1.5294040000000004,
 -1.7694079599999997,
 -1.8870099003999998,
 -1.9446348511959997,
 -1.9728710770860403,
 -1.9867068277721591,
 -1.9934863456083578,
 -1.9968083093480953]
```


Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo simples




Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo mais complicado

- Seja a função real $z = f(x, y) = 4x^2 + 2y^2 - 2xy$
- A derivada primeira de z em relação a x é dada por: $\frac{dz}{dx} = 8x - 2y$
- A derivada primeira de z em relação a y é dada por: $\frac{dz}{dy} = 4y - 2x$



Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo mais complicado

- Definição da função $z = f(x, y)$ original:

```
# A função abaixo, calcula o valor de f(x,y)
def func_z(x,y):
    return 4*x**2 + 2*y**2 - 2*x*y
```

- Cálculo da derivada primeira de z em relação a x e y :

```
# A função a seguir, calcula o valor da derivada de z em função de x
def dx(x,y):
    return 8*x - 2*y

# Cálculo da derivada de z em função de y
def dy(x,y):
    return 4*y - 2*x
```

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo mais complicado

- Função para calcular o gradiente descendente de $f(x, y)$:
 - Iniciamos a descida com chute inicial para x e y ($x_0 = 30$ e $y_0 = 40$)
 - Faremos o mesmo com o valor de α , ajustando-o para $\alpha = 0,05$ (faremos com que a taxa de atualização seja de 5%)
 - Faremos um total de 100 iterações

```
theta_x = 30
theta_y = 40

alpha = 0.05

epoch = 100

def gradient_descent_xy(theta_x, theta_y, alpha, epoch):

    grad_x = []
    grad_y = []

    grad_x.append(theta_x)
    grad_y.append(theta_y)

    for i in range(epoch):
        current_theta_x = theta_x - alpha * dx(theta_x, theta_y)
        current_theta_y = theta_y - alpha * dy(theta_x, theta_y)
        grad_x.append(current_theta_x)
        grad_y.append(current_theta_y)

        theta_x = current_theta_x
        theta_y = current_theta_y

    return theta_x, theta_y, grad_x, grad_y
```

Método Variacional - Parte II

4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo mais complicado

- Valores de x ao longo das iterações:

```
gd2[2]
[30,
 22.0,
 16.7,
 13.04,
 10.407,
 ...
 1.173016304018012e-06,
 9.87000969415312e-07,
 8.304836942929711e-07,
 6.987867163849628e-07,
 5.879740666212515e-07]
```

- Valores de y ao longo das iterações:

```
gd2[3]
[40,
 35.0,
 30.2,
 25.83,
 21.967999999999996,
 ...
 2.831911870045047e-06,
 2.382831126437839e-06,
 2.004964998091802e-06,
 1.6870203679027387e-06,
 1.4194949659606872e-06]
```

Método Variacional - Parte II


4. Componentes

4.1 Método de minimização do Gradiente Descendente

Um exemplo mais complicado

Em breve...

🎲 Notebook com [Atividade Prática 6](#)




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

- Fontes de incerteza são uma característica intrínseca a qualquer sistema dinâmico
- Na década de 1960, Edward N. Lorenz, mostrou que a atmosfera possui previsibilidade de suas semanas
 - Experimentos gêmeos 
- Desafio:
 - Como fazer com que os modelos atuais possam prever bem dentro deste limite (e além dele)?



Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

- Os modelos de Previsão Numérica de Tempo (PNT) são realizados dentro de uma estrutura de modelagem que compreende:
 1. Modelo numérico
 2. Observações
 3. Sistema de assimilação de dados
 - 👉 A boa análise é o resultado da conjugação destes 3 fatores
- Tarefa da modelagem e assimilação de dados:
 - Uma vez estabelecido o processo de modelagem, as fontes de incerteza devem ser abordadas para que o seu impacto seja mínimo

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

- Em geral, as fontes de incerteza do processo de modelagem são representadas por:
 - Modelo numérico (e.g., dinâmica e física)
 - Observações (e.g., medição, instrumento, grau de processamento)
 - Sistema de assimilação de dados (e.g., operadores de observação, modelos adjunto e tangente linear, tamanho do conjunto de um ensemble)
- A matriz de covariâncias dos erros de previsão (**B**), representa a covariância do "erro" (uma estimativa) do modelo
- Na assimilação de dados, estes erros são modelados em matrizes de covariâncias que tratam das relações espaço-temporais entre as quantidades observadas e diagnosticadas/prognosticadas
- Função custo 3DVar:

$$J(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}^b)^T \mathbf{B}^{-1}(\mathbf{x} - \mathbf{x}^b) + \frac{1}{2}[\mathbf{y}^o - \mathbf{H}(\mathbf{x})]^T \mathbf{R}^{-1}[\mathbf{y}^o - \mathbf{H}(\mathbf{x})]$$

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

- Em geral, as fontes de incerteza do processo de modelagem são representadas por:
 - Modelo numérico (e.g., dinâmica e física)
 - Observações (e.g., medição, instrumento, grau de processamento)
 - Sistema de assimilação de dados (e.g., operadores de observação, modelos adjunto e tangente linear, tamanho do conjunto de um ensemble)
- A matriz de covariâncias dos erros de previsão ($\mathbf{B}$), representa a covariância do "erro" (uma estimativa) do modelo
- Na assimilação de dados, estes erros são modelados em matrizes de covariâncias que tratam das relações espaço-temporais entre as quantidades observadas e diagnosticadas/prognosticadas
- Função custo 3DVar:

$$J(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}^b)^T \mathbf{B}^{-1}(\mathbf{x} - \mathbf{x}^b) + \frac{1}{2}[\mathbf{y}^o - \mathbf{H}(\mathbf{x})]^T \mathbf{R}^{-1}[\mathbf{y}^o - \mathbf{H}(\mathbf{x})]$$

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Importância da matriz $\mathbf{B}$

- Considerando a assimilação de uma única variável, podemos escrever o operador observação linearizado $\mathbf{H}$ como:

$$\mathbf{H} = [0, \dots, 0, 1, 0, \dots, 0]$$

- Partindo-se da equação geral da análise $\mathbf{x}^a = \mathbf{x}^b + (\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} (\mathbf{H}^T \mathbf{R}^{-1}) [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)]$, obtemos:

$$\begin{aligned} (\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})(\mathbf{x}^a - \mathbf{x}^b) &= (\mathbf{H}^T \mathbf{R}^{-1}) [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)] \\ \mathbf{x}^a - \mathbf{x}^b &= \frac{\mathbf{H}^T \mathbf{R}^{-1} [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)]}{\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}} \end{aligned}$$

- Multiplicando-se e dividindo-se por $\mathbf{B}$ o lado direito, obtemos:

$$\begin{aligned} \mathbf{x}^a - \mathbf{x}^b &= \frac{\mathbf{B} \mathbf{H}^T \mathbf{R}^{-1} [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)]}{1 + \mathbf{B} \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}} \\ \mathbf{x}^a - \mathbf{x}^b &= \frac{\mathbf{B} \mathbf{H}^T \mathbf{R}^{-1} [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)]}{\frac{\mathbf{R} + \mathbf{H} \mathbf{B} \mathbf{H}^T}{\mathbf{R}}} \\ \mathbf{x}^a - \mathbf{x}^b &= \frac{\mathbf{B} \mathbf{H}^T [\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)]}{\mathbf{R} + \mathbf{H} \mathbf{B} \mathbf{H}^T} \end{aligned}$$

- Como a suposição inicial foi a de que há apenas uma observação e apenas um ponto de grade a ser analisado, os termos $\mathbf{y}^o - \mathbf{H}(\mathbf{x}^b)$ e $\mathbf{R} + \mathbf{H} \mathbf{B} \mathbf{H}^T$ são escalares. Com isso, pode-se afirmar que:

$$\mathbf{x}^a - \mathbf{x}^b \propto \mathbf{B} \mathbf{H}^T$$

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Forma idealizada da matriz **B**

- Devido ao tamanho das variáveis do modelo, o tamanho completo de uma matriz **B** é extremamente grande. Normalmente, ela é da ordem de $10^6 \times 10^6$, o que, em sua forma atual, não pode ser armazenado em nenhum computador
- Esse problema é simplificado por meio do uso de um conjunto ideal de variáveis de análise, sobre as quais a análise é realizada
 - Essas variáveis são geralmente chamadas de "variáveis de controle"
- As variáveis de controle são escolhidas de forma que as correlações cruzadas entre elas sejam mínimas
 - Isso implica em menos termos fora da diagonal em **B**
 - Dessa forma remove-se a dependência cruzada entre essas variáveis
- O balanço entre as variáveis de análise (como os campos de massa e vento) é obtido com coeficientes de regressão pré-calculados
- Os erros de previsão são modelados como uma distribuição Gaussiana, com variâncias e parâmetros de escala de comprimento (lengthscale) pré-computados para cada uma das variáveis de controle da análise

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC

- Cálculo da matriz $\mathbf{B}$ - Método NMC ♦
 - Preconiza que as correlações espaciais dos erros do modelo são semelhantes às correlações entre as previsões de 48 e 24 horas
 - Amplamente utilizado e aplicado em métodos variacionais
 - Facilidade de acesso aos pares de previsões de 48 e 24 horas

♦ NMC: *National Modeling Center* (Parish e Derber, 1992: *The National Meteorological Center's Spectral Statistical-Interpolation Analysis System* - [link](#))

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - considerações

- O método NMC preconiza que a correlação espacial dos erros do modelo são semelhantes à correlação espacial das diferenças entre as previsões de 48 e 24 horas
 - Para um modelo regional, pode-se considerar a diferença entre as previsões de 24 e 12 horas - **por quê?**
 - **Suposição:** crescimento linear dos erros de previsão durante as primeiras horas de previsão (similar ao método de perturbação da previsão por conjuntos utilizando EOFs)
- Exemplo de par de previsões válido (modelo BAM):
 - GFCTCPT20131224182013122618F.fct.TQ0299L064 (previsão 48 horas)
 - GFCTCPT20131225182013122618F.fct.TQ0299L064 (previsão 24 horas)

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - algoritmo

1. Leitura do cabeçalho dos arquivos espectrais a fim de se determinar quantos pares estão disponíveis para o processamento (nesta etapa, são lidos a data, o horário da previsão e o tipo de coordenada vertical – neste caso, sigma puro)
2. Leitura dos pares propriamente ditos e conversão para ponto de grade
3. Leitura e organização dos pares de previsões de 48 e 24 horas
4. Remoção de viés (em toda a coluna vertical)
5. Cálculo das matrizes de balanço que permitirão as transformações entre função de corrente (ψ) e as componentes desbalanceadas de velocidade potencial (χ), pressão em superfície (p) e temperatura (T)
6. Cálculo das variâncias dos erros de cada uma das variáveis de controle (ψ, χ, q, oz, cw, p)
7. Cálculo dos comprimentos de correlação verticais (em unidades inversas em ponto de grade)
8. Cálculo dos comprimentos de correlação horizontais (em km)

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - algoritmo


- O fluxo atmosférico pode ser decomposto em duas componentes:
 1. Balanceada (i.e., baixa frequência - *slow manifold*)
 2. Não balanceada (i.e., alta frequência)
- No GSI, as variáveis de controle são ψ , Tv_u , χ_u , ps_u , $RH_{q1,q2}$, oz , cw e sst
 - O balanço entre estas duas componentes é dado por de matrizes que projetam a função de corrente sobre a parte balanceada de Tv_b , χ_b , ps_b :
 - **agvin**: $Tv_b = \mathbf{G}\psi \rightarrow Tv = Tv_u + \mathbf{G}\psi$
 - **bgvin**: $\chi_b = \mathbf{c}\psi \rightarrow \chi = \chi_u + \mathbf{c}\psi$
 - **wgvn**: $ps_b = \mathbf{w}\psi \rightarrow ps = ps_u + \mathbf{w}\psi$
- ψ define boa parte do incremento de análise para Tv_b , χ_b , ps_b
- $\mathbf{G}$, $\mathbf{c}$ e $\mathbf{w}$ contabilizam as correlações entre ψ e Tv_b , χ_b , ps_b , respectivamente

Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplo da contribuição de ψ para Tv




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - verificação

- Inspeção visual das estruturas da matriz calculada
- Comparação com uma matriz de referência
- Para a matriz $\mathbf{B}$ global do GSI, pode-se utilizar o software [GSIError](#)
 - 🚗 Test drive disponível no [Google Colab](#)




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos




Método Variacional - Parte II

4. Componentes

4.2 Matriz de covariâncias dos Erros de Previsão

Método NMC - exemplos



Método Variacional - Parte II

5. Visão geral sobre o método 4DVar

- O 4DVar é uma extensão do método 3DVar
 - Permite que sejam assimiladas observações distribuídas dentro de um intervalo de tempo (t_0, t_n) , considerando a dinâmica do modelo 💡
 - A função custo inclui um termo que mede a distância em relação ao background no início do intervalo (t_0) e o somatório (ao longo do tempo) para cada incremento de observação no seu tempo

$$J[\mathbf{x}(t_0)] = \frac{1}{2}[\mathbf{x}(t_0) - \mathbf{x}_b(t_0)]^T \mathbf{B}_0^{-1}[\mathbf{x}(t_0) - \mathbf{x}_b(t_0)] + \frac{1}{2} \sum_{i=0}^N [\mathbf{y}_i - H(\mathbf{x}_i)]^T \mathbf{R}_i^{-1}[\mathbf{y}_i - H(\mathbf{x}_i)]$$

- A variável de controle é o estado inicial do modelo (variáveis de estado) no tempo t_0 , i.e., $\mathbf{x}(t_0)$
- A análise, no final do intervalo de tempo, é dado pela integração do modelo, i.e., $\mathbf{x}(t_n) = M_0[\mathbf{x}(t_0)]$
 - Isto significa que o modelo é usado como *strong constraint*, i.e., a análise deve satisfazer as equações do modelo


Método Variacional - Parte II

5. Visão geral sobre o método 4DVar

- No 4DVar, o modelo tangente linear representa a linearização do modelo não linear
 - Propaga as diferenças entre o modelo e o estado verdadeiro (perturbações) ao longo do tempo (**como o erro se propaga no tempo?**)

$$\mathbf{x}_{t+1} = M(\mathbf{x}_t)$$
$$\delta \mathbf{x}_{t+1} = \mathbf{M}_t \delta \mathbf{x}_t$$

- 🐼 M_t é o Jacobiano de $\mathbf{M}$
- O modelo adjunto, é o transposto do modelo tangente linear
 - Faz o processo inverso, ou seja, propaga a sensibilidade - do tempo futuro para o passado (**como a observação corrige o estado inicial?** 🤖)
- No 4DVar, a matriz $\mathbf{B}$ é fixa no tempo (tal como no 3DVar), mas as covariâncias são propagadas de forma implícita pelo modelo



Video sobre os 20 anos de operações do 4DVar no ECMWF:
[link](#)

Método Variacional - Parte II

6. Atividades realizadas no CPTEC com o método variacional

- Projetos operacionais desenvolvidos/aplicados no CPTEC utilizando o 3DVar:
 - RPSAS (~2000): Regional PSAS
 - Utilizava o modelo regional Eta e o sistema de assimilação de dados PSAS
 - GPSAS (~2000): Global PSAS
 - Utilizava o modelo global MCGA e o sistema de assimilação de dados PSAS
 - G3DVar (~2010):
 - Utilizava o modelo global MCGA e o sistema de assimilação de dados GSI
 - SMNA (~2020): Sistema de Modelagem Numérica e Assimilação de dados
 - Utiliza o modelo global BAM e o sistema de assimilação de dados GSI
 - MONAN+JEDI (a partir de 2024): próxima geração do sistema de assimilação de dados do CPTEC
 - Utiliza o modelo multiescalas MONAN e o sistema de assimilação de dados JEDI

🤔 Dúvidas

🔗 <https://cfbstarz.github.io/met563-3/>

👤 <https://github.com/cfbstarz/MET563-3>

✉️ carlos.bastarz@inpe.br

